

Akademik Makale Analizi

Advancements in End-to-End Audio Style Transformation:
A Differentiable Approach for Voice Conversion and Musical Style Transfer

1. Makale Bilgileri

Başlık:	Advancements in End-to-End Audio Style Transformation: A Differentiable Approach for Voice Conversion and Musical Style Transfer
Yazar(lar):	Shashwat Aggarwal, Shashwat Uttam, Sameer Garg, Shubham Garg, Kopal Jain, Swati Aggarwal
Kurum:	Netaji Subhas University of Technology, New Delhi, India
Dergi:	AI (MDPI)
Cilt / Sayı:	Volume 6, Issue 1, Article 16
Yıl:	2025 (Yayımlandı: 17 Ocak 2025)
DOI:	10.3390/ai6010016
URL:	https://www.mdpi.com/2673-2688/6/1/16
Preprint:	https://www.preprints.org/manuscript/202411.0396/v1

2. Özet

Bu çalışma, ses stillerini dönüştürmek için tamamen farklılaştırılabilir, uçtan uca bir ses dönüşüm ağı sunmaktadır. Önerilen yöntem, encoder-decoder mimarisine dayalı olup global koşullandırma mekanizması kullanır. Sistemin üç temel avantajı vardır: (1) paralel ifadeler, ara fonetik temsillere veya konuşmacıdan bağımsız ASR sistemlerine ihtiyaç duymaz; (2) kelime dağarcığından bağımsızdır ve hedef kimlikten bağımsız şekilde ses stillerini dönüştürebilir; (3) tek atışlı (one-shot) ses dönüşümü gerçekleştirir. Sistem, ses dönüşümü ve müzikal stil transferi görevlerinde test edilmiş ve yedi farklı mevcut sistemi geride bırakmıştır. Hem görülen hem de görülmeyen hedef senaryolarda rekabetçi performans elde edilmiştir. Subjektif ve objektif metrikler kullanılarak değerlendirilen bu yaklaşım, özellik mühendisliğini basitleştirir ve ses dönüşümlerinin uygulanabilirliğini farklı alanlara genişletir.

3. Anahtar Bulgular

- Paralel veri gereksinimi ortadan kaldırılmıştır: Sistemin çalışması için paralel utterance'lara veya zaman hizalamasına ihtiyaç yoktur.
- Kelime dağarcığından bağımsızlık: Global koşullandırma mekanizması sayesinde, model eğitim sırasında görülmeyen dillere ve konuşmacılara adapte olabilir.
- ASR sistemlerine bağımlılık yoktur: Ara fonetik temsillere ihtiyaç duymadan, doğrudan akustik özellikler üzerinde çalışır.

- Yüksek performans: CMU Arctic ve L2 Arctic veri setlerinde yedi baseline sistemin üzerinde MOS (Mean Opinion Score) deęerleri elde edilmiřtir.
- Çoklu grev bařarı: Aynı mimari hem ses dnřm (voice conversion) hem de mzikal stil transferi iin bařarıyla kullanılmıřtır.
- Cinsiyet ve milliyet transferi: İntra ve inter cinsiyet/milliyet dnřmlerinde doęal ve anlaşılır sonular retilmiřtir.
- Stil embeddinglerde kmelenme: t-SNE grselleřtirmeleri, reference encoder'ın aynı hedef kimlik sınıflarına ait sesleri bařarıyla kmeledięini gstermiřtir.
- Latent discriminator etkisi: Adversarial eęitim sonrası encoder'ın hedef kimlikten baęımsız latent temsiller ęrendięi doęrulanmıřtır.

4. Metodoloji Özeti

4.1. Genel Mimari

Sistem üç ana bileşenden oluşur: Encoder, Decoder ve Reference Encoder. Encoder ve decoder ağları, gated konvolüsyonel katmanlar (Gated CNN) ve çift yönlü LSTM'lerden (Bidirectional LSTM) oluşur. Gated CNN'ler spektral ilişkileri yakalarken, LSTM'ler temporal özellikleri modeller. Residual bağlantılar ve instance normalization eğitimi stabilize eder.

4.2. Reference Encoder

Reference encoder, hedef konuşmacının stil özelliklerini (timbre, konuşma hızı, tınlama) kodlar. Bu stil embeddingleri, decoder'a global koşullandırma olarak verilir. Bu sayede model, kaynak konuşmanın içeriğini korurken hedef stilini uygular.

4.3. Eğitim Süreci

Eğitim iki aşamalıdır:

- Aşama 1: Reconstruction loss kullanılarak temel model eğitilir. Encoder kaynak ses özelliklerini kodlar, reference encoder hedef stil bilgisini çıkarır, decoder bu ikisini birleştirerek hedef özelliklerini üretir.
- Aşama 2: WGAN (Wasserstein GAN) tabanlı ince ayar yapılır. Latent discriminator eklenerek encoder'ın hedef kimlikten bağımsız temsiller öğrenmesi sağlanır. Bu, modelin görülmeyen konuşmacılara genelleme yeteneğini artırır.

4.4. Veri Setleri

Ses dönüşümü için CMU Arctic (7 konuşmacı, US İngilizce aksanları) ve L2 Arctic (20 ana dili İngilizce olmayan konuşmacı: Hindi, Korece, Mandarin, İspanyolca, Arapça) veri setleri kullanılmıştır. Müzikal stil transferi için IRMAS veri seti (10 farklı müzik enstrümanı) kullanılmıştır. Toplam 12 konuşmacı (6 kadın, 6 erkek, 6 farklı milliyet) ve 6 enstrüman (piyano, saksafon, keman, flüt, trompet, akustik gitar) seçilmiştir. Veri 5:1 oranında eğitim-test olarak bölünmüştür.

4.5. Ses Formatı ve Özellikler

Ses sinyalleri 16 kHz örnekleme hızında işlenmiştir. 50 ms frame uzunluğu ve 12.5 ms frame shift kullanılmıştır. 128 Mel frekans bandı ve 40 MFCC özelliği çıkarılmıştır. Sentez için Griffin-Lim algoritması kullanılmıştır.

5. Sonuçlar ve Tartışma

5.1. Nicel Sonuçlar

Subjektif deęerlendirmeler (MOS - Mean Opinion Score) 5 normal iřitme duyusuna sahip insan deęerlendirici tarafından 5'li skala üzerinden yapılmıřtır (1:kötü, 2:zayıf, 3:orta, 4:iyi, 5:mükemmel).

Yöntem	Ses Dönüşümü (Görülen)	Müzikal Transfer (Görülen)
Ground Truth	4.53	4.07
CVAE	3.31	3.08
C-Seq2Seq	3.50	3.26
MSVC	3.77	-
Önerilen Yöntem	3.72	3.50
Yöntem	Ses Dönüşümü (Görülmeyen)	Müzikal Transfer (Görülmeyen)
MSVC	3.51	-
Önerilen Yöntem	3.44	3.36

5.2. Önemli Gözlemler

- Baseline karşılařtırması: Önerilen yöntem CVAE ve C-Seq2Seq gibi yerel kořullandırma kullanan yöntemleri açık farkla geçmiřtir. MSVC (ASR tabanlı any-to-any sistem) ile rekabetçi sonuçlar elde edilmiřtir.
- Görülmeyen hedefler: Model, eğitim sırasında görmedięi konuşmacılara bile yüksek kalitede transfer yapabilmektedir (MOS: 3.44 ses dönüşümü, 3.36 müzikal transfer).
- Spektral keskinlik: Üretilen mel spektrogramların keskinlięi, doğal konuşmaya yakın olduęunu göstermektedir.
- Stil kodlaması: t-SNE görselleřtirmeleri, reference encoder'ın aynı kimlik sınıflarını başarıyla kümeledięini ortaya koymuřtur.

5.3. Latent Discriminator Etkisi

Latent discriminator ile adversarial eğitim sonrası, doğrulama doğruluęu (verification accuracy) belirgin řekilde düşmüřtür. Bu, encoder'ın hedef kimlikten baęımsız latent temsiller öğrendięini doğrular:

Görev	L.A. Öncesi (%)	L.A. Sonrası (%)
Ses Dönüşümü	93.2	57.15
Müzikal Transfer	86.34	69.1

6. Sınırlamalar ve Gelecek Çalışmalar

6.1. Mevcut Sınırlamalar

- Griffin-Lim algoritması kullanımı: Ses sentezi için iteratif faz rekonstrüksiyon yöntemi olan Griffin-Lim kullanılmıştır. Bu, modern neural vocoder'lara (WaveNet, HiFi-GAN) göre daha düşük kalitede ses üretir.
- Veri seti sınırlılığı: Test, nispeten küçük CMU Arctic, L2 Arctic ve IRMAS veri setleri ile yapılmıştır. Daha büyük ve çeşitli veri setlerinde test edilmesi gerekir.
- Gerçek zamanlı işleme: Makalede gerçek zamanlı işleme performansı hakkında bilgi verilmemiştir. Pratik uygulamalar için latency önemlidir.
- Prosodi kontrolü: Model prosodik özellikleri (pitch contour, timing, vurgu) üzerinde ince ayarlı kontrol sunmamaktadır.
- Çok konuşmacılı senaryolar: Birden fazla konuşmacının olduğu ortamlarda veya gürültülü koşullarda performans test edilmemiştir.
- Dil bağımsızlığı iddiası: Kelime dağarcığından bağımsız olduğu iddia edilse de, farklı dil aileleri ve ton dilleri üzerinde kapsamlı test yapılmamıştır.

6.2. Önerilen Gelecek Çalışmalar

- Neural vocoder entegrasyonu: Griffin-Lim yerine WaveNet, HiFi-GAN veya UnivNet gibi modern neural vocoder'ların entegrasyonu ses kalitesini önemli ölçüde artıracaktır.
- Prosodi kontrolü eklenmesi: Pitch, ritim ve vurgu gibi prosodik özelliklerin bağımsız kontrolü için ayrı encoder'lar eklenebilir.
- Gerçek zamanlı implementasyon: Model optimizasyonu ve hafif mimariler ile gerçek zamanlı işleme kapasitesi geliştirilebilir.
- Multimodal öğrenme: Video (lip-sync) veya metin modaliteleri eklenerek çok modlu ses dönüşümü araştırılabilir.
- Zero-shot dil adaptasyonu: Tamamen görülmemiş dillerde stil transferi için meta-learning yaklaşımları denenebilir.
- Duygu ve konuşma stili transferi: Sadece konuşmacı kimliğinin yanında, duygu durumu ve konuşma tarzının da transfer edilmesi araştırılabilir.
- Gürültü dayanıklılığı: Gerçek dünya gürültüsü ve akustik koşullarında robustluk için denoising mekanizmaları eklenebilir.
- Büyük ölçekli veri ile eğitim: LibriSpeech, VoxCeleb gibi büyük veri setlerinde eğitim yapılarak genelleme kapasitesi artırılabilir.

7. Kritik Değerlendirme / Yorum

7.1. Güçlü Yönler

- Pratik yaklaşım: Paralel veri ve ASR sistemi gereksinimleri ortadan kaldırılarak, metodoloji önemli ölçüde basitleştirilmiştir. Bu, gerçek dünya uygulamaları için büyük bir avantajdır.
- Kelime dağarcığı bağımsızlığı: Global kondisyonlama mekanizması sayesinde model, farklı dillere ve görülmeyen konuşmacılara kolayca adapte olabilir. Bu özellik, çok dilli uygulamalar için kritik öneme sahiptir.
- Çoklu görev başarısı: Aynı mimarinin hem ses dönüşümü hem de müzikal stil transferi için kullanılabilmesi, modelin genelleştirilebilirliğini gösterir.
- Interpretability vurgusu: Çalışma, kullandığı LSTM ve CNN tabanlı mimarinin açıklanabilir olduğunu vurgular. XAI (Explainable AI) bağlamında bu önemli bir katkıdır.
- Kapsamlı değerlendirme: Hem subjektif (MOS) hem de objektif (spectral sharpness, t-SNE clustering) metrikler kullanılarak çok yönlü değerlendirme yapılmıştır.
- Adversarial eğitim stratejisi: Latent discriminator kullanımı, modelin görülmeyen konuşmacılara genelleme yeteneğini artırmıştır.

7.2. Zayıf Yönler ve Tartışmalı Noktalar

- Griffin-Lim algoritması: Modern ses sentezi standartlarının gerisinde bir yöntem kullanılması, ses kalitesini sınırlamaktadır. 2025 yılında bu teknolojiyi kullanmak çalışmanın önemli bir eksikliğidir.
- Veri seti boyutu: Özellikle deep learning çağında, kullanılan veri setleri oldukça küçüktür. 12 konuşmacı ve 6 enstrüman ile yapılan testler, genelleme kapasitesi hakkında sınırlı bilgi verir.
- Baseline seçimi: Karşılaştırılan baseline'lar nispeten eskidir. 2024-2025 yıllarındaki diffusion tabanlı veya flow-matching tabanlı yöntemler ile karşılaştırma yapılmamıştır.
- Gerçek zamanlı performans eksikliği: Pratik uygulamalar için kritik olan latency ve throughput metrikleri rapor edilmemiştir.
- Prosodi kontrolünün olmaması: Sadece genel stil transferi yapılmakta, prosodik özelliklerin ince ayarlı kontrolü sağlanmamaktadır. Bu, bazı uygulamalar için önemli bir kısıttır.
- Ablasyon çalışması eksikliği: Mimarinin farklı bileşenlerinin (gated CNN, LSTM, reference encoder) katkılarını gösteren detaylı ablasyon çalışması yapılmamıştır.
- Dil çeşitliliği sınırlı: Test edilen diller çoğunlukla Indo-Avrupa dil ailesinden ve İngilizce aksanlı konuşmacılardır. Ton dilleri, aglütinatif diller gibi farklı yapıdaki diller test edilmemiştir.

7.3. Alan İçindeki Konumu

Bu çalışma, audio style transfer alanında orta düzeyde bir katkı sunmaktadır. Paralel veri gereksiniminin ortadan kaldırılması ve kelime dağarcığı bağımsızlığı önemli pratik avantajlardır. Ancak, teknolojik olarak 2017-2019 dönemi metodolojilerine yakın bir yaklaşım sergiler. 2024-2025 döneminde diffusion modelleri (örn. DiffVC, GuideDiff), flow-matching yöntemleri (örn. R-VC, CosyVoice-VC) ve büyük ölçekli language model tabanlı yaklaşımlar (örn. LM-VC, Uniaudio) çok daha yüksek kalitede ses üretimi sağlamaktadır. Bu perspektiften bakıldığında, çalışma metodolojik basitlik ve pratiklik açısından değerli olsa da, son teknoloji performansı sunmamaktadır.

Çalışmanın en güçlü yanı, interpretability vurgusudur. XAI (Explainable AI) alanındaki tartışmalara katkı yaparak, LSTM ve CNN tabanlı mimarilerin attention mekanizmalarına göre daha açıklanabilir olduğunu savunması önemlidir. Bu, özellikle klinik veya güvenlik-kritik uygulamalarda önem kazanabilir.

7.4. Uygulama Potansiyeli

Önerilen sistem aşağıdaki alanlarda potansiyel kullanım alanlarına sahiptir:

- Dublaj ve post-produksiyon: Film ve dizi dublajında aktör seslerinin korunması veya değiştirilmesi.
- Kişiselleştirilmiş TTS sistemleri: Minimum veri ile kişiye özel ses sentezi.
- Müzik prodüksiyonu: Enstrüman tınısı transferi ve sound design.
- Erişilebilirlik uygulamaları: Konuşma bozukluğu olan bireyler için ses protezi.
- Eğitim ve dil öğrenme: Farklı aksanlar ve konuşma stillerinin öğretimi.
- Eğlence sektörü: Oyun ve VR/AR uygulamalarında dinamik ses dönüşümü.

Ancak, Griffin-Lim kullanımı ve gerçek zamanlı işleme kapasitesinin netleştirilmemesi, pratik deployment için ciddi engeller oluşturmaktadır. Çalışmanın akademik bir proof-of-concept olarak değerli olduğu, ancak endüstriyel uygulamalar için önemli iyileştirmeler gerektirdiği söylenebilir.

7.5. Sonuç

Bu makale, audio style transfer alanında metodolojik basitlik ve pratiklik açısından değerli bir katkı sunmaktadır. Paralel veri ve ASR gereksinimlerinin ortadan kaldırılması, sistemi uygulanabilir kılar. Ancak, kullanılan teknolojiler (Griffin-Lim, nispeten eski baseline'lar) ve sınırlı test senaryoları, çalışmanın etkisini azaltmaktadır. 2025 yılı standartlarında değerlendirildiğinde, çalışma orta düzeyde bir bilimsel katkı olarak görülebilir. Neural vocoder entegrasyonu, daha büyük veri setlerinde test ve modern baseline'larla karşılaştırma yapılması durumunda, çalışmanın etkisi önemli ölçüde artacaktır.

Genel Değerlendirme: Çalışma, interpretable AI vurgusu ve pratik yaklaşımıyla değerli bir akademik katkıdır, ancak state-of-the-art performans açısından geride kalmaktadır. Eğitim ve araştırma amaçlı olarak uygun bir baseline çalışması olarak görülebilir.

Referanslar ve Baęlantılar

DOI: 10.3390/ai6010016

MDPI Yayınevi Sayfası: <https://www.mdpi.com/2673-2688/6/1/16>

Preprint Versiyonu: <https://www.preprints.org/manuscript/202411.0396/v1>

ResearchGate: <https://www.researchgate.net/publication/388111548>

Bu analiz belgesi, makaleyi kapsamlı bir şekilde inceleyerek akademik değeriendirme sağlamaktadır. Tüm görüşler ve yorumlar, mevcut literatür ve alan bilgisine dayanmaktadır.