

Diffusion Models for Audio Generation: Akademik Makale Analizi

Tarih: 14 Ekim 2025

Giriş

Bu belge, Diffusion Models (Difüzyon Modelleri) ve audio generation uygulamaları üzerine yapılmış önemli akademik çalışmaların detaylı analizini içermektedir. Diffusion models, son yıllarda görüntü, ses ve video üretiminde devrim yaratmış, özellikle audio synthesis alanında WaveNet ve GAN-tabanlı yaklaşımlara güçlü bir alternatif sunmuştur.

1. Denoising Diffusion Probabilistic Models (DDPM)

Makale Bilgileri

Başlık: Denoising Diffusion Probabilistic Models

Yazarlar: Jonathan Ho, Ajay Jain, Pieter Abbeel

Yayımlandığı Yer: NeurIPS 2020 (34th Conference on Neural Information Processing Systems)

Yıl: 2020

arXiv: [arXiv:2006.11239](https://arxiv.org/abs/2006.11239)

Bağlantı: <https://arxiv.org/abs/2006.11239>

GitHub: <https://github.com/hojonathanho/diffusion>

Özet

Bu çalışma, nonequilibrium thermodynamics (termodinamik denge-dışı süreçler) prensiplerinden ilham alan latent variable modeller sınıfı olan diffusion probabilistic modeller kullanarak yüksek kaliteli görüntü sentezi sonuçları sunmaktadır. En iyi sonuçlar, denoising score matching ile Langevin dynamics arasındaki yeni bir bağlantıya göre tasarlanmış ağırlıklandırılmış variational bound üzerinde eğitim yaparak elde edilmiştir. Modeller doğal olarak progressive lossy decompression scheme'e sahiptir ve bu autoregressive decoding'in bir genellemesi olarak yorumlanabilir. Unconditional CIFAR10 veri setinde 9.46 Inception

score ve 3.17 state-of-the-art FID score elde edilmiştir. 256x256 LSUN'da ProgressiveGAN'e benzer sample kalitesi elde edilmiştir.

Anahtar Bulgular

- Difüzyon modelleri ile yüksek kaliteli görüntü üretimi: CIFAR10'da state-of-the-art FID score (3.17)
- Forward difüzyon: veri dağılımına kademeli olarak Gaussian gürültü ekleme
- Reverse difüzyon: gürültüden veri oluşturma (denoising süreci)
- Denoising score matching ile Langevin dynamics arasında yeni teorik bağlantı
- Simplified training objective: ağırlıklandırılmış variational lower bound
- Progressive lossy decompression: autoregressive modellere alternatif
- GAN ve VAE'ye göre daha stabil eğitim: mode collapse yok

Metodoloji Özeti

Forward Difüzyon Süreci (q):

- Markov zinciri: $x_0 \rightarrow x_1 \rightarrow x_2 \rightarrow \dots \rightarrow x_t$
- Her adımda Gaussian gürültü ekleme: $q(x_t|x_{t-1}) = N(x_t; \sqrt{(1-\beta_t)}x_{t-1}, \beta_t I)$
- Variance schedule: $\beta_1, \beta_2, \dots, \beta_t$ (linear veya cosine)
- T adım sonra: $x_t \approx N(0, I)$ (pure noise)

Reverse Difüzyon Süreci (p θ):

- Learned Markov chain: $x_t \rightarrow x_{t-1} \rightarrow \dots \rightarrow x_0$
- Neural network $\varepsilon\theta(x_t, t)$: t zamanındaki gürültüyü tahmin eder
- $p\theta(x_{t-1}|x_t) = N(x_{t-1}; \mu\theta(x_t, t), \Sigma\theta(x_t, t))$
- Loss: simplified variational bound (MSE on predicted noise)

Eğitim Algoritması:

1. $x_0 \sim q(x_0)$: veri setinden sample al
2. $t \sim \text{Uniform}(1, T)$: rastgele timestep seç
3. $\varepsilon \sim N(0, I)$: rastgele gürültü üret
4. Gradient descent: $\nabla_{\theta} \|\varepsilon - \varepsilon\theta(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{(1-\bar{\alpha}_t)}\varepsilon, t)\|^2$

Sampling (İnference):

- $x_t \sim N(0, I)$ başlangıcı
- $t = T$ 'den $t = 1$ 'e kadar iterasyon
- Her adımda: $x_{t-1} = f(x_t, \varepsilon\theta(x_t, t), t) + z$ (z: noise term)
- Output: x_0 (generated sample)

Sonuçlar ve Tartışma

Image Generation Performansı:

- CIFAR10 (unconditional): FID 3.17 (state-of-the-art), Inception Score 9.46
- LSUN 256x256: ProgressiveGAN ile karşılaştırılabilir kalite

- Sample diversity: GAN'lere göre daha iyi mode coverage

Eğitim Stabilitesi:

- GAN'lerin mode collapse problemi yok
- VAE'nin posterior collapse problemi yok
- Single loss function: karmaşık adversarial training gerekmez

Progressive Generation:

- Coarse-to-fine generation: önce genel yapı, sonra detaylar
- Lossy compression interpretation: farklı t seviyelerinde farklı detay düzeyleri

Sınırlamalar ve Gelecek Çalışmalar

Sampling Hızı:

- Yavaş inference: T adım gerektirir (tipik $T = 1000$)
- Her step bir neural network forward pass gerektir
- GAN'lere göre çok daha yavaş (GAN: single forward pass)

İyileştirme Yönleri:

- Accelerated sampling: daha az step ile generation (DDIM, fast sampling schemes)
- Learned variance: variance schedule'ı öğrenme
- Conditional generation: class, text, veya diğer conditions
- Audio ve video domain'lerine genişletme

Kritik Değerlendirme / Meta-Analiz

DDPM makalesi, generative modeling alanında paradigma değişikliği yaratan temel bir çalışmadır. Diffusion modellerin teorik temellerini sağlamlaştırarak, bu model sınıfını pratik uygulamalar için erişilebilir hale getirmiştir.

Simplified training objective özellikle önemlidir. Ağırlıklandırılmış variational bound, karmaşık adversarial training veya posterior collapse problemleri olmadan stabil eğitim sağlar. Bu, GAN ve VAE'nin uzun yıllardır karşılaştığı zorlukları zarif bir şekilde çözmektedir.

Thermodynamics'ten ilham alan forward-reverse süreç metaforu sadece matematiksel olarak güçlü değil, aynı zamanda sezgisel olarak da anlaşılabilir. Veriyi kademeli olarak gürültüye dönüştürüp geri döndürme fikri, autoregressive ve flow-based modellerden farklı bir bakış açısı sunmaktadır.

Ancak, pratik deployment açısından ciddi bir sınırlama vardır: yavaş sampling. 1000 step gerektiren inference, real-time uygulamalar için kabul edilemez. Bu durum, sonraki çalışmaların (DDIM, fast sampling schemes) odak noktası olmuştur.

DDPM'nin etkisi sadece görüntü üretimiyle sınırlı kalmamış; audio (DiffWave), video, 3D shape generation ve hatta protein design gibi alanlara yayılmıştır. 2020'den bu yana, diffusion modeller AI research'ün en aktif alanlarından biri haline gelmiştir.

2. DiffWave: A Versatile Diffusion Model for Audio Synthesis

Makale Bilgileri

Başlık: DiffWave: A Versatile Diffusion Model for Audio Synthesis

Yazarlar: Zhifeng Kong, Wei Ping, Jiaji Huang, Kexin Zhao, Bryan Catanzaro

Yayımlandığı Yer: ICLR 2021 (International Conference on Learning Representations)

Yıl: 2020 (arXiv), 2021 (ICLR)

arXiv: [arXiv:2009.09761](https://arxiv.org/abs/2009.09761)

Bağlantı: <https://arxiv.org/abs/2009.09761>

Demo: <https://diffwave-demo.github.io/>

Özet

Bu çalışmada, conditional ve unconditional waveform generation için çok yönlü bir diffusion probabilistic model olan DiffWave önerilmektedir. Model non-autoregressive'dir ve beyaz gürültü sinyalinin sentez sırasında sabit sayıda adımla Markov zinciri aracılığıyla yapılandırılmış waveform'a dönüştürür. Veri olasılığı üzerindeki variational bound'un bir varyantını optimize ederek verimli şekilde eğitilir. DiffWave, mel spektrograma koşullandırılmış neural vocoding, class-conditional generation ve unconditional generation dahil olmak üzere farklı waveform generation görevlerinde yüksek kaliteli audio'lar üretir. DiffWave'in güçlü bir WaveNet vocoder'ı ile konuşma kalitesi açısından eşleştiği (MOS: 4.44'e karşı 4.43) ve aynı zamanda büyüklük mertebeleri daha hızlı sentezlediği gösterilmiştir. Özellikle, çeşitli otomatik ve insan değerlendirmelerinden audio kalitesi ve sample çeşitliliği açısından zorlayıcı unconditional generation görevinde autoregressive ve GAN-tabanlı waveform modellerini önemli ölçüde geride bırakmaktadır.

Anahtar Bulgular

- İlk başarılı diffusion-based audio waveform generator
- WaveNet kalitesine eşdeğer (MOS: 4.44 vs 4.43), ancak WaveNet'ten 500x daha hızlı
- Non-autoregressive: paralel waveform generation
- Versatile: conditional (mel-spectrogram), class-conditional, unconditional generation
- Small footprint: 2.64M parametrelili model 22.05kHz audio için 5.6x real-time hızında
- Unconditional generation: GAN ve autoregressive modelleri audio quality ve diversity'de geçer
- Single loss function: ELBO-based, auxiliary losses gerekmez
- Flexible: flow-based modellerin architectural constraints'i yok

Metodoloji Özeti

DiffWave Mimarisi:

- Bidirectional dilated convolutions: WaveNet-benzeri yapı, ama causal değil
- Residual connections: her dilated conv block residual output verir
- Dilation cycle: $[1, 2, 4, \dots, 512] \times n_cycles$ (e.g., 30 layers)
- Noise level embedding: sinusoidal positional encoding for timestep t
- Output: $\hat{\epsilon}_t(x_t, c, t)$ - tahmin edilen gürültü (c : conditional input)

Conditional Generation (Neural Vocoding):

- Input: mel-spectrogram (düşük çözünürlüklü akustik features)
- Upsampling: transposed convolutions ile mel-spec waveform resolution'a çıkarılır
- Conditioning: upsampled features her layer'a eklenir
- Görev: mel-spectrogram $\rightarrow$ high-quality waveform

Unconditional Generation:

- Hiçbir conditioning signal olmadan pure noise'dan audio üretme
- En zorlayıcı görev: model tüm variability'yi öğrenmeli
- Previous models (WaveNet, GAN): nonsensical sounds veya mode collapse
- DiffWave: diverse ve realistic audio samples

Eğitim Detayları:

- Dataset: LJSpeech (neural vocoding), SC09 (class-conditional), various (unconditional)
- $T = 50$ diffusion steps (training ve inference)
- Linear noise schedule: $\beta_1 = 1e-4$, $\beta_t = 0.02$
- Optimizer: Adam, batch size 16, 1M iterations

Sonuçlar ve Tartışma

Neural Vocoding (Conditional):

- MOS: 4.44 (DiffWave) vs 4.43 (WaveNet) vs 4.45 (Ground Truth)
- WaveNet kalitesine eşdeğer, ancak çok daha hızlı
- DiffWave BASE ($T=20$): 2.1x real-time (FP32), MOS: 4.35
- DiffWave BASE (Fast): 5.6x real-time, hala yüksek kalite

Unconditional Generation:

- Inception Score: DiffWave significantly better than GAN-based models
- Sample diversity: mode collapse yok, gerçekçi ve çeşitli sesler
- Subjective evaluation: insan değerlendiriciler DiffWave'i tercih etti

Hız Karşılaştırması:

- WaveNet: ~500x slower than real-time (without optimized kernels)
- DiffWave: 1.1x - 5.6x faster than real-time (configuration'a bağlı)
- Flow-based (WaveFlow): >40x real-time, ama DiffWave daha küçük ve **약간** better quality

Sınırlamalar ve Gelecek Çalışmalar

Hız İyileştirme:

- Flow-based models kadar hızlı değil (WaveGlow, WaveFlow)
- Daha az diffusion step ile generation: quality-speed trade-off
- Fast sampling techniques: DDIM-style approaches

Model Genişletme:

- Multi-speaker TTS: speaker conditioning
- Music generation: longer-term structure modeling
- Audio effects: style transfer, denoising, enhancement

Architectural İyileştirmeler:

- Daha efficient architectures: transformer-based, attention mechanisms
- Learned noise schedules: adaptive diffusion
- Latent diffusion: compressed latent space'te diffusion

Kritik Değerlendirme / Meta-Analiz

DiffWave, diffusion models'in audio domain'ine başarılı adaptasyonunun ilk örneklerinden biridir. DDPM'nin görüntü üretimindeki başarısından ilham alarak, audio waveform generation için pratik bir çözüm sunmuştur.

En çarpıcı başarı, WaveNet kalitesine ulaşırken 500x hız kazancı sağlamasıdır. Bu, diffusion models'in sadece teorik olarak değil, pratik olarak da uygulanabilir olduğunu göstermiştir. WaveNet'in yıllarca süren autoregressive dominance'ını kıran önemli bir dönüm noktasıdır.

Non-autoregressive yapı kritik bir avantajdır. Paralel generation, modern GPU hardware'ini tam olarak kullanabilir ve real-time applications için yol açar. Bu, WaveNet ve Paralel WaveNet'in karmaşık distillation sürecine zarif bir alternatiftir.

Unconditional generation sonuçları özellikle etkileyicidir. GAN-based models'in mode collapse ve quality sorunlarına karşı, DiffWave diverse ve realistic samples üretebilmektedir. Bu, diffusion models'in generative modeling'de GAN'lere üstünlüğünü audio domain'de de göstermektedir.

Ancak, flow-based models (WaveGlow) kadar hızlı değildir. Bu, real-time interactive applications için hala bir sınırlama olabilir. Sonraki çalışmalar (WaveGrad, PriorGrad) bu hız sorununu address etmeye çalışmıştır.

DiffWave'in etkisi büyüktür: Grad-TTS, WaveGrad, audio style transfer için diffusion models gibi birçok sonraki çalışmaya ilham vermiştir. Audio generation'da yeni bir research direction açmıştır.

3. Grad-TTS: A Diffusion Probabilistic Model for Text-to-Speech

Makale Bilgileri

Başlık: Grad-TTS: A Diffusion Probabilistic Model for Text-to-Speech

Yazarlar: Vadim Popov, Ivan Vovk, Vladimir Gogoryan, Tasnima Sadekova, Mikhail Kudinov

Yayımlandığı Yer: ICML 2021 (38th International Conference on Machine Learning)

Yıl: 2021

arXiv: [arXiv:2105.06337](https://arxiv.org/abs/2105.06337)

Bağlantı: <https://arxiv.org/abs/2105.06337>

PMLR: <https://proceedings.mlr.press/v139/popov21a.html>

Demo: <https://grad-tts.github.io/>

GitHub: <https://github.com/huawei-noah/Speech-Backbones/tree/main/Grad-TTS>

Özet

Son zamanlarda, denoising diffusion probabilistic modeller ve generative score matching, karmaşık veri dağılımlarını modellemede yüksek potansiyel gösterirken stochastic calculus bu tekniklere esnek inference şemaları sağlayan birleşik bir bakış açısı sunmuştur. Bu makalede, encoder tarafından tahmin edilen ve Monotonic Alignment Search aracılığıyla metin girişiyle hizalanan gürültüden mel-spektrogramları kademeli olarak dönüştürerek üreten score-based decoder'a sahip yeni bir text-to-speech modeli olan Grad-TTS'i tanıtıyoruz. Stochastic differential equations framework'ü, conventional diffusion probabilistic modellerini farklı parametrelerle gürültüden veri rekonstrüksiyonu durumuna genellememize yardımcı olur ve ses kalitesi ile inference hızı arasındaki trade-off'u açıkça kontrol ederek bu rekonstrüksiyonu esnek hale getirmemizi sağlar. Subjektif insan değerlendirmesi, Grad-TTS'in Mean Opinion Score açısından state-of-the-art text-to-speech yaklaşımlarıyla rekabet edici olduğunu göstermektedir.

Anahtar Bulgular

- İlk end-to-end diffusion-based TTS modeli (encoder + score-based decoder)
- Score-based generative modeling: SDE framework kullanarak flexible inference
- Monotonic Alignment Search (MAS): metin ve audio otomatik hizalama
- Controllable quality-speed trade-off: inference time'da diffusion step sayısı ayarlanabilir
- State-of-the-art TTS kalitesi: Tacotron 2 ve Glow-TTS ile karşılaştırılabilir MOS

- Inference hızı: 10 diffusion steps ile Tacotron 2'den 2x hızlı, hala yüksek kalite
- Multi-speaker support: 247 speaker ile LibriTTS üzerinde eğitilmiş

Metodoloji Özeti

Grad-TTS Mimarisi:

- Encoder: text $\rightarrow$ latent representation (phonemes, durations)
- Duration Predictor: her phoneme için duration prediction
- Monotonic Alignment Search: encoder output ile target mel-spec hizalama
- Score-based Decoder: diffusion process ile mel-spectrogram generation
- U-Net architecture: encoder output ile conditioned

Stochastic Differential Equations (SDE):

- Forward SDE: veriyi kademeli olarak Gaussian noise'a dönüştürür
- Reverse SDE: noise'dan veri rekonstrüksiyonu (Anderson 1982)
- Probability Flow ODE: deterministic alternative to reverse SDE
- Score function: $\nabla \log p(x)$: veri dağılımının gradienti
- Neural network $s_\theta(x, t)$: score function tahmin eder

Eğitim Süreci:

1. Encoder eğitimi: reconstruction loss + duration prediction loss
2. Alignment: MAS ile phonemes ve mel-spec frames hizalama
3. Decoder eğitimi: score matching loss (denoising score matching)
4. Joint optimization: encoder ve decoder end-to-end eğitilir

Inference (Sampling):

- Text input $\rightarrow$ Encoder $\rightarrow$ aligned representation
- Random Gaussian noise $\rightarrow$ Decoder (reverse diffusion)
- N steps: user-controllable (10-50 steps tipik)
- Output: mel-spectrogram $\rightarrow$ Vocoder (HiFi-GAN) $\rightarrow$ waveform

Sonuçlar ve Tartışma

Speech Quality (MOS):

- Grad-TTS (N=10): MOS 4.13 ± 0.09
- Tacotron 2: MOS 4.17 ± 0.08
- Glow-TTS: MOS 4.16 ± 0.09
- Ground Truth: MOS 4.45 ± 0.06
- Grad-TTS state-of-the-art modellerle competitive

Inference Hızı:

- Grad-TTS (N=10): Tacotron 2'den $\sim 2x$ daha hızlı
- Quality-speed trade-off: N=4 ile hızlı ama düşük kalite, N=50 ile yüksek kalite ama yavaş
- Optimal: N=10-20 arası, iyi balance

Multi-Speaker Performance:

- • LibriTTS 247 speakers ile eğitilmiş
- • Speaker embedding conditioning: her speaker için ayrı voice
- • Zero-shot speaker adaptation potansiyeli

Sınırlamalar ve Gelecek Çalışmalar

Inference Hızı:

- • Hala Tacotron 2'den sadece 2x hızlı, daha fazla acceleration gerekli
- • Fast sampling techniques: DDIM, progressive distillation
- • Real-time TTS için additional optimization

Model İyileştirmeleri:

- • Prosody control: emotion, speaking style
- • Zero-shot voice cloning: few-shot adaptation
- • Multilingual TTS: code-switching support

Architectural Directions:

- • Transformer-based encoders: better long-range dependencies
- • Latent diffusion: compressed space'te diffusion
- • End-to-end waveform generation: vocoder'sız direkt audio

Kritik Değerlendirme / Meta-Analiz

Grad-TTS, diffusion models'in text-to-speech domain'ine başarılı entegrasyonunun öncü örneklerinden biridir. Score-based generative modeling ve stochastic differential equations framework'ünü TTS için uyarlaması teorik olarak zarif ve pratik olarak etkilidir.

Monotonic Alignment Search'ün dahil edilmesi önemli bir katkıdır. External alignment tools gerekmeden end-to-end training, modeli daha basit ve robust hale getirir. Bu, Tacotron 2'nin attention mechanism'ine göre daha güvenilir alignment sağlar.

Controllable quality-speed trade-off çok değerlidir. Kullanıcı veya uygulama gereksinimlerine göre inference time'da diffusion steps sayısını ayarlayabilmek, flexibility açısından büyük avantajdır. Bu, production deployment için kritik bir özelliktir.

State-of-the-art TTS modelleriyle competitive kalite, diffusion models'in sadece görüntü ve raw audio için değil, structured generation görevleri (TTS) için de viable olduğunu gösterir. Bu, sonraki çalışmaların (NaturalSpeech, VALL-E gibi) yolunu açmıştır.

Ancak, inference hızı hala bir sınırlamadır. Tacotron 2'den sadece 2x hızlı olması, real-time interactive applications için yeterli olmayabilir. Sonraki çalışmalar (ProDiff, FastDiff) bu soruna odaklanmıştır.

Grad-TTS'in etkisi önemlidir: diffusion-based TTS arařtırmalarının temelini atmıř, score-based modeling'in audio generation'daki potansiyelini göstermiřtir. TTS research community'sinde yeni bir direction amıřtır.

Genel Sonuç ve Öneriler

Diffusion Models'in Audio Generation'daki Evrimi:

Bu üç makale, diffusion models'in audio generation alanındaki evrimini göstermektedir:

- 1. DDPM (2020): Görüntü üretimi için temel diffusion framework. Teorik foundation ve practical algorithms.
- 2. DiffWave (2020): Audio waveform generation için ilk başarılı diffusion model. WaveNet kalitesi, paralel generation.
- 3. Grad-TTS (2021): End-to-end diffusion-based TTS. Score-based modeling, flexible inference, state-of-the-art quality.

Audio Style Transfer için Öneriler:

- • DiffWave-benzeri mimari timbre transfer için güçlü bir temel sunabilir
- • Conditional generation: source audio + style reference → styled output
- • Latent diffusion: compressed latent space'te style manipulation daha verimli olabilir
- • Score-based modeling: continuous-time formulation, flexible sampling
- • Real-time için: fast sampling techniques (DDIM, DPM-Solver) kullanılmalı

WaveNet vs Diffusion Models:

Karşılaştırmalı analiz:

- • Kalite: Her ikisi de yüksek kalite, diffusion models **약간** daha iyi diversity
- • Hız: DiffWave >> WaveNet (500x), ama flow models < diffusion models
- • Eğitim: Diffusion models daha stabil (no mode collapse, posterior collapse)
- • Flexibility: Diffusion models daha flexible (controllable sampling, interpolation)
- • Architecture: WaveNet architectural constraints, diffusion models daha general

Güncel Trendler (2024-2025):

- • Latent Diffusion Models: compressed space'te diffusion (daha hızlı)
- • Consistency Models: single-step generation, diffusion quality'si
- • Flow Matching: optimal transport-based, daha efficient training
- • Hybrid approaches: Diffusion + Transformer, Diffusion + GAN
- • Large-scale audio models: AudioLDM, Make-An-Audio, MusicGen

Kaynaklar

1. Ho, J., Jain, A., & Abbeel, P. (2020). Denoising Diffusion Probabilistic Models. NeurIPS 2020. arXiv:2006.11239. <https://arxiv.org/abs/2006.11239>

2. Kong, Z., Ping, W., Huang, J., Zhao, K., & Catanzaro, B. (2020). DiffWave: A Versatile Diffusion Model for Audio Synthesis. ICLR 2021. arXiv:2009.09761. <https://arxiv.org/abs/2009.09761>

3. Popov, V., Vovk, I., Gogoryan, V., Sadekova, T., & Kudinov, M. (2021). Grad-TTS: A Diffusion Probabilistic Model for Text-to-Speech. ICML 2021, PMLR 139:8599-8608. arXiv:2105.06337. <https://arxiv.org/abs/2105.06337>

4. The Annotated Diffusion Model - Hugging Face Blog: <https://huggingface.co/blog/annotated-diffusion>

5. DiffWave Demo Page: <https://diffwave-demo.github.io/>

6. Grad-TTS Demo Page: <https://grad-tts.github.io/>